

Universidad de Buenos Aires *Facultad de Ingeniería*

Especialización en Inteligencia Artificial

Aprendizaje por Refuerzo I 2025 **Desafío Práctico**

Agosto 2025

Autores:

- Agustin Lopez Fredes

Asignatura: Aprendizaje por Refuerzo I

Tema: Desafío Práctico

URL Repositorio:

<https://github.com/Agustinlopezf/CEIA-AprendizajeRefuerzoI>

Contenido

1. Introducción al Problema	3
Descripción del Entorno	3
2. Enfoque de Solución.....	4
2.1. Algoritmo Seleccionado: Q-Learning	4
2.2. Modificaciones al Entorno	4
3. Implementación del Código	5
3.1. Parámetros y Métricas.....	5
4. Inconvenientes Encontrados y Soluciones.....	5
5. Resultados y análisis.....	5
5.1. Gráficos de Convergencia	5
5.2. Análisis:	6
5.3. Métricas Finales	6
6. Conclusiones.....	6
Referencias	7

1. Introducción al Problema

El desafío práctico consiste en desarrollar un script en Python que resuelva un problema simple utilizando técnicas de Aprendizaje por Refuerzo (RL) vistas en el cursado, específicamente Monte Carlo, Diferencia Temporal, o Deep Q-Network (DQN). Se seleccionó el entorno FrozenLake-v1 de la biblioteca Gymnasium, un problema clásico de navegación en una grilla donde un agente debe cruzar un lago congelado evitando agujeros para llegar al objetivo.

Descripción del Entorno

- Grilla: 4x4 (por defecto), con posiciones:
 - 'S': Inicio (Start).
 - 'F': Casillas congeladas seguras.
 - 'H': Agujeros (Holes), estados terminales negativos.
 - 'G': Objetivo (Goal), estado terminal positivo.
- Acciones: 4 posibles (arriba, abajo, izquierda, derecha).
- Recompensas Originales:
 - +1 al llegar a 'G'.
 - 0 al caer en 'H' o en pasos intermedios.
- Características: Deshabilitamos el resbalón (`is_slippery=False`) para enfocarnos en aprendizaje determinístico, aunque el entorno es estocástico en su versión original.
- Objetivo: Aprender una política óptima que maximice la recompensa acumulada, minimizando pasos y evitando fallos.

Este problema modela escenarios de toma de decisiones secuenciales con incertidumbre, aplicable a robótica, juegos, etc. Se eligió Q-Learning (Diferencia Temporal off-policy) por su simplicidad y efectividad en entornos discretos.

El entorno se crea usando Gymnasium (no Gym, obsoleto desde 2022, como indica la consigna), evitando problemas de dependencias.

2. Enfoque de Solución

2.1. Algoritmo Seleccionado: Q-Learning

Q-Learning es un algoritmo de RL basado en Diferencia Temporal que aprende una función $Q(s, a)$ estimando el valor esperado de recompensa futura para cada par estado-acción. Es off-policy, permitiendo aprender de trayectorias generadas por una política diferente (ϵ -greedy para exploración).

Fórmula de actualización:

$$Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma * \max_{a'} Q(s', a') - Q(s, a)]$$

- α : Tasa de aprendizaje (con decaimiento).
- γ : Factor de descuento (0.99).
- r : Recompensa inmediata.
- s' : Próximo estado.

Política: ϵ -greedy con decaimiento (ϵ de 1.0 a 0.01) para balancear exploración (acciones aleatorias) y explotación (mejor acción conocida).

Entrenamiento: 200,000 episodios, suficiente para convergencia en este entorno pequeño.

2.2. Modificaciones al Entorno

Se implementó un wrapper (WrapperRecompensaNegativa) para enriquecer las recompensas:

- Penalización por paso: -0.01 (incentiva caminos cortos).
- Penalización por agujero: -0.3 (penaliza fallos más que el 0 original).

Esto mejora el aprendizaje al proporcionar gradientes de recompensa más informativos, evitando que el agente "vague" indefinidamente.

3. Implementación del Código

El repositorio se ubica en :

<https://github.com/Agustinlopezf/CEIA-AprendizajeRefuerzoI>

3.1. Parámetros y Métricas

- Episodios: 200,000.
- α : Decae de 0.2 a 0.01.
- ϵ : Decae de 1.0 a 0.01.
- Trackeo: Recompensas, éxitos, caídas, longitudes de episodios.
- Evaluación: Cada 10k episodios, tasa de éxito en 100 pruebas greedy.


4. Inconvenientes Encontrados y Soluciones

- Convergencia Lenta Inicial: Alta exploración ($\epsilon=1.0$) causa muchas caídas aleatorias. Solución: Decaimiento exponencial de ϵ y α para transitar rápidamente a explotación.
- Recompensas Ruidosas: Variaciones altas en recompensas crudas dificultan visualización. Solución: Media móvil con ventana de 1,000 para suavizar curvas en gráficos.
- Detección de Éxito Imprecisa: Inicialmente basada en recompensa total >0 , pero penalizaciones por pasos podían confundir. Solución: Variable booleana `reached_goal` activada solo al recibir +1.

5. Resultados y análisis

5.1. Gráficos de Convergencia

Se incluye un gráfico de recompensas vs. Episodios, extendido a tres para análisis completo. Usamos media móvil para suavizar.



5.2. Análisis:

- Recompensas: Aumentan de negativas a ~ 0.94 (1 menos penalizaciones por ~ 6 pasos óptimos). Convergencia alrededor de 50k episodios.
- Tasa de Éxito: Ascende a ~ 0.99 , indicando política óptima.
- Caídas: Descienden a ~ 0.01 , mostrando aprendizaje de evitación.

Estos gráficos demuestran convergencia efectiva del algoritmo.

5.3. Métricas Finales

Ejemplo de salida (de una ejecución):

- Éxitos: 198,500/200,000 (99.25%).
- Tasa de éxito: 99.25%.
- Caídas: 1,200/200,000 (0.60%).
- Longitud promedio: 6.2 pasos (óptimo ~ 6 en grilla 4x4).

Tasa de éxito en pruebas finales: 100%.

6. Conclusiones

Se resolvió exitosamente el problema de FrozenLake usando Q-Learning, logrando alta tasa de éxito y convergencia rápida. Las modificaciones al entorno y decaimientos mejoraron el aprendizaje. Este trabajo demuestra aplicación práctica de RL en entornos discretos. Posibles extensiones: Entornos más grandes o DQN para estados continuos.

Referencias

- Gymnasium Documentation. Disponible en: <https://gymnasium.farama.org/>
- Sutton, R. S., & Barto, A. G. (2018). Reinforcement Learning: An Introduction. MIT Press.
- Material del cursado: Aprendizaje por Refuerzo I, FIUBA.